

React 应用 Playwright 测试选择器层面隐性误修复研究

Research on Selector-Level Silent False Healing in Playwright Test Repair for React Applications

高东彪

(软视软件(苏州)有限公司, 江苏苏州 215000)

Gao Dongbiao

(Zoom Video Communications (Suzhou), Inc., Suzhou 215000, China)

摘要: 大语言模型驱动的 UI 测试自愈正用于降低脆弱定位器的维护成本。本文在 ReproBreak 数据集 koenig 项目 75 个真实 Playwright 可达失效用例上, 于选择器解析层面测量代码模型 qwen2.5-coder:7b 在缺乏行为验证时的行为: 在对抗性构造场景下, 78.7% 的用例中模型给出可解析但指向错误元素的选择器 (即选择器层面隐性误修复的对抗性上界), 附加“无匹配则放弃”软提示后结果不变。给出 HealReact 系统 L1 静态基底 (AST 抽取、意图标注、确定性校准), 静态覆盖 80.6% 真实失效目标, L3 修复器在可达用例上 top-1 选择器精确匹配率达 77.3%。结果表明: 无人值守持续集成自愈场景下, 引入行为重放验证器是必要的下一步; 本文数字为静态解析层面的诊断性指标, 与运行时测试通过率之间的换算仍需真实重放。

关键词: 测试自愈; 大语言模型; Playwright; React; 隐性误修复

中图分类号: TP311.5 **文献标识码:** A

Abstract: LLM-driven self-healing for end-to-end UI tests is increasingly used to absorb the maintenance cost of brittle locators. On real-world Playwright break cases from the ReproBreak dataset, across 75 reachable koenig breaks, we measure – at the selector-resolution level – that qwen2.5-coder:7b emits a wrong yet resolver-valid Playwright selector in 78.7% of adversarial-by-construction cases (an adversarial upper bound on selector-level silent false healing); an explicit “abstain” prompt guardrail produces identical numbers. HealReact’s L1 substrate (AST extractor + intent labeller + deterministic calibration) reaches 80.6% of the 93 real break targets statically; on top of it the L3 healer attains 77.3% top-1 exact-element selector matching on reachable breaks. We make the empirical case that a behavioural-replay oracle is a necessary next layer for unattended CI healing; all numbers here are static, selector-resolution diagnostics, and their mapping to runtime test-pass rates still requires real replay.

Keywords: software testing; self-healing test; large language model; Playwright; React; abstract syntax tree

0 引言

维护脆弱的 UI 测试套件是现代 Web 工程中持续存在的维护成本。一次 CSS 类名重命名、一次 React 组件的重新嵌套, 或是一次行为不变的处理函数重构, 都足以让数十个端到端 (E2E) Playwright 测试断裂。这一问题在 GUI 测试脚本演化的研究综述中被多次列为关键挑战 [1-2]。无论是工业界工具 (如 Healenium [3]) 还是日益增长的学术工作 [4-5], 给出的自然回应都是自愈: 在定位器失效时, 自动将

其重写为指向新 DOM 中等价元素的形式。近年来, 大语言模型 (LLM) 被广泛引入软件测试任务 [6-7], 自动测试修复 (含定位器修复) 是其中最直接受益的方向之一。

这一前景看似乐观, 近期文献也使该问题看起来接近解决。Joseph [4] 通过一个确定性可访问性阶梯在单一 demo 上报告了 100% 通过率; 当代基于 LLM 的定位器修复工作通常借助一致性守门规则报告修复成功率或解释一致性。然而这些指标共享一处结构性盲区: 它们衡量的是打过补丁的测试是否通过, 而非补丁是否指向开发者真正期望的元素。一个总能找到“某个”可解析选择器 (任何属性近似的元

作者简介: 高东彪 (1986—), 男, 工程师, 学士; 研究方向: AI 在软件测试中的应用。
通信作者: 高东彪, E-mail: gdb_1986@163.com。

素皆可)的修复器存在隐蔽的危险性——每一次“通过但错指”的修复都会掩盖一次本应被作为回归暴露的真实 UI 变更。

我们在 ReproBreak [5] 数据集中的真实 Playwright 失效用例上直接测量这种失败模式。在 koenig 的 75 个可达失效用例上, 结果令人不安:

- **F1 ——隐性误修复是默认行为。**当真实目标元素被强制从候选集中移除时, 朴素 LLM 修复器 (qwen2.5-coder:7b [8]) 在 **78.7%** 的用例中给出语法正确但元素错误的选择器 (59/75); 仅 17.3% 的情形下能正确放弃。
- **F2 ——软提示放弃指令形同虚设。**在系统提示中追加明确的“如无候选契合则放弃”守门规则后, 结果数字完全一致 (两版本均为 59/75, $\Delta = 0$), 表明模型并未将该规则纳入决策。
- **F3 ——跨应用泛化受锚点文化间接性的制约。**在另一 React+Playwright 代码库 (payloadcms/payload, 319 个失效配对) 上, 由于其采用 BEM 风格的模板字面量类名、当前静态抽取器无法对其求值, 原始可达率从 koenig 的 80.6% 跌至 3.8%。本文将其诊断为一处明确且可修复的盲区, 而非对方法本身的否定。

前两个发现为无人值守自愈流水线引入行为重放验证层提供了直接的经验性动机。第三个发现给出一条可证伪的跨应用泛化论断: 任何仅在单一应用上完成基准测试的定位器修复工具, 都很可能高估其泛化能力, 因为锚点文化 (data-testid vs data-kg-* vs BEM 模板字面量) 在不同 React 代码库之间存在显著差异。

此外, 我们介绍 HealReact 的 L1 基底——一个 AST 抽取器加一个带确定性后置校准的 LLM 派生意图标注器——它静态可达 koenig 93 个失效目标中的 80.6%; 在其之上, 一个小型本地 L3 修复器在可达用例上正确回答了 77.3% (在完整数据集上为 62.4% 的静态修复代理¹)。两个廉价确定性杠杆——testId 加权检索与强锚点后置过滤——经二因子析因分离后各带来边际改进、合计 3 个新正确用例、零回归 (方向一致, McNemar 未达显著), 表明确定性后处理可作为比提示工程更可靠的安全网。

¹我们全文使用“静态修复代理”而非“端到端修复”: 解析器在元素层面的精确一致性与 Playwright 通过率相关, 但既不是其下界也不是其上界 (静态精确匹配的选择器可能在 visibility/timing 约束下运行时失败; 静态不匹配的选择器也可能在重渲染 DOM 中运行时通过)。两者之间的换算需要基于 Docker 的真实重放。

贡献。 (i) 在真实 Playwright 数据集上对隐性误修复的诊断性测量, 以及对软提示放弃指令无效的展示 (§3); (ii) HealReact 的 L1 基底作为一个可证伪、可本地运行的静态层 (§2); (iii) 两个确定性安全杠杆经二因子析因分离, 各自带来边际改进、合计 3 增 0 减 (方向一致但在 $n = 75$ 下 McNemar 未显著, 见 §3)。

78.7% 是选择器层面的对抗性上界 (对抗性构造); 将其与 koenig 真正不可达的 18/93 用例朴素相乘, 得到无人值守工作负载下约 15% 的粗略上界估计 (而非测得的部署率, 详见 §3)。即便作为上界估计, 我们 (§4) 仍认为这已经高到足以拒绝在 CI 中无人值守地自动提交 LLM 提出的选择器补丁。

1 背景与相关工作

定位器脆性与基准数据集。 ReproBreak [5] 是迄今最大的可复现定位器失效语料 (来自 359 个带 Cypress/Playwright 测试的 Web 仓库的 449 个可复现失效)。我们将 tryghost/koenig [9] 的 Playwright 切片 (93 个可复现失效, 分布于 19 个 commit) 用作主要基底。

自愈工具。 脆弱测试 (flaky test) 与测试自愈属于相邻问题域, 前者的综述工作为后者提供了重要参考 [10]。Healenium [3] 在运行时通过 DOM 相似度修复 Selenium 选择器, 是最流行的工业界基线。Joseph [4] 基于 DOM 可访问性树确定性地重新抽取选择器, 在单个电子商务 demo 上报告了 100% 通过率, 是确定性静态修复轴上最强的已发表基线, 也是与本文 L1 基底最直接的比较对象。截至本文写作时, 尚未发现有同行评议的 LLM 定位器修复工具在真实 Playwright 基准数据集上报告隐性误修复率; 与之最接近的当代工作主要关注修复成功率或解释一致性, 两者均不直接约束本文探针所针对的失败模式。

缺失的部分。 上述工作均未在真实基准数据集上隔离隐性误修复——即修复器给出语法通过、但指向错误元素的选择器、从而遮蔽真实 UI 变更的比率。Joseph 在一个右侧答案按构造一定可达的 demo 上报告了通过率; ReproBreak 提供了数据基底但未在其上评估任何修复器。§3 通过一个对抗性构造的探针填补这一空缺。




图1 HealReact 流水线。L1 (本文) 是静态 AST 锚点基底，意图标注层在本文中仅在 32 元素的小规模构造样例(fixture)上评估；L3 是 §3 中评估的 LLM 修复器。L4 为行为重放验证器 (virtual oracle)，其必要性由 §3 中的对抗性误修复探针在经验上得到充分动机化，作为后续工作给出。

React 相关细节。 koenig-lexical [9, 11] 是一个基于 React + Lexical 的现代富文本编辑器，其 Playwright 套件在很大程度上依赖自定义 data-kg-* 属性 (约占其失效的一半)，而非 data-testid。payloadcms/payload [12] 是一个 Next.js 后台 UI，其 CSS 类名遵循 BEM [13]，使用 ``${baseClass}__suffix`` 模板字面量——这些字面量对 React 可见，但对纯字面量的 AST 抽取器不可见。这两种锚点文化的对比是我们跨应用发现的依据 (§3, F3)。

2 HealReact L1 静态基底

HealReact 的 L1 层是 L3 修复器与任何未来行为 oracle (L4) 所运行其上的静态基底。它由三部分组成 (图 1)。

AST 抽取器。 基于 ts-morph [14] 构建的抽取器遍历目标目录下的每个 .tsx/.jsx 文件，并为每个交互式 JSX 元素发出一条 JSON LocatorSheet 记录。每条记录包含元素 tag、父链、role、data-testid、aria-label、id、className、自由文本内容，关键还包括任意自定义 data-* 属性 (捕获在 dataAttrs 映射中)。抽取器还把任何承载稳定锚点 (data-testid、data-cy、data-kg-*, aria-label，或驼峰 dataTestId/testId/testID prop) 的 JSX 元素都视为可交互——而不仅是规范 HTML tag 集。仅这一项改动就将 koenig-lexical 上的锚点覆盖率从 22% 提升到 48%、解析器命中率从 0% 提升到

71%，说明现代 React 的脆性中有相当部分藏在自定义包装组件里。

意图标注器与校准器 (小规模构造样例上的评估)。 HealReact 还包含一个 LLM 意图标注流程 (经 Ollama [15] 运行的 qwen2.5:3b)，它依据组件源码与 JSX 上下文为每个交互元素生成简短的功能性意图标签 (例如 submit-order-button、toggle-email-notification)；随后由一个十条规则 (A–J) 构成的确定性校准层负责识别并降低可疑标签的置信度，可疑模式包括兄弟集合的塌缩标签、把 HTML tag 直接当名词的退化、以及 role 与 intent 不匹配等。被标记的记录将被重新提交给 qwen2.5-coder:7b 重打标签，形成“先廉价后昂贵”的分级验证机制。**范围说明：**本文对意图层的评估限定在 32 元素的构造样例集(fixture)上；§3 中针对真实失效用例的所有数字仅使用抽取器输出的锚点与词法检索，不使用 L1 意图标签。真实代码库上对意图稳定性的大规模评估超出本文范围。

定位器解析器作为可证伪的透镜。 我们构建了一个 Playwright 选择器解析/匹配器，它接受任意选择器表达式 (page.locator、getByTestId、getByRole、waitForSelector、原始 CSS) 并返回它会匹配的 LocatorSheet 记录集。这是 §3 中每个论断被验证的透镜：可达性是“断裂的选择器是否能解析到 sheet 中的某条记录？”；L3 正确性是“解析器是否把 LLM 提议的选择器与 ground truth 选择器映射到同一元素？”。构建这个透镜迫使我们处理引号感知的嵌套参数、动态 JS 表达式属性值、以及裸属性选择器；早期版本由于解析器 bug 把可达率虚抬到 85–98%，我们现在在诚实性审计中明确标注了这一点。

头条数字。 在 koenig-lexical 的 19 个失效 commit 上，抽取器每 commit 平均产出约 400 条 LocatorSheet 记录 (跨 commit 范围 314–489)，解析器在静态层面可达真实 Playwright 失效目标的 $75 / 93 = 80.6\%$ 。剩余 18 个用例需要运行时 DOM (例如 Lexical 框架在运行时才渲染出的 `<p>` 节点)，属于经典的运行时 DOM 捕获范畴，由 HealReact 的 L2 层负责。

3 三个实证发现

下文所有数字都可由开放脚本 `heal_baseline.py`、`false_heal_probe.py` 与 `cross_app_probe.py` 在 `healreact/bench/cases/` 下的 JSON 工件上复现。完整 sweep（两个 L3 变体 + 两个 false-heal 探针）在 Apple M5 Pro / 48 GB 上仅用 Apple Metal 加速的墙钟约为 8 min。

复现配置。 为便于复现，本文固定以下设置：L3 修复器与意图标注器分别经 Ollama 运行 `qwen2.5-coder:7b` 与 `qwen2.5:3b`，二者均取 `temperature=0`（贪心解码、单次采样）；候选检索采用加性 token 重叠打分，权重为 `testId×3`、`dataAttr key/value×2`、`aria/id/class/text/path×1`，取 top- k 候选（ k 与各探针配置一并记录在工件 JSON 中）。每个失效用例的逐条记录（用例 id、所属 commit、断裂选择器、`ReproBreak new_locator`、候选数、模型原始输出、解析结果、是否判为误修复）连同所用模型版本摘要、`koenig` 的 19 个失效 commit 与 payload 的 HEAD 快照标识，均随 `healreact/bench/cases/` 工件一并发布，作为本文结果的复现与审计依据。**代码与数据可用性：**上述脚本与 JSON/CSV 工件作为本文补充材料提供，并冻结于发表时的版本（含各脚本运行命令、模型 tag/digest 与 commit 标识）；若期刊不支持补充材料，可向作者索取冻结版本归档。表 1–5 中的每一项原始计数（样本数、放弃/误修复/未解析、排除规则）均可由该工件直接复算。

共享 L3 协议。 在 F1 与 F2 中，L3 修复器都经由 Ollama 以 `temperature=0` 调用 `qwen2.5-coder:7b`。用户提示包含：(i) 原样给出的断裂 Playwright 选择器；(ii) 失效行附近的 ± 3 行测试源码；(iii) 来自 `LocatorSheet` 的 top- k 候选，按加性 token 重叠打分检索（`testId × 3`、`dataAttr key/value × 2`、`aria/id/class/text/path × 1`）。模型必须给出三行：SELECTOR、CANDIDATE_IDX、RATIONALE（纯文本，非 JSON：在模型反复在选择器中输出未转义引号后放弃了 JSON）。解析器的 tie 处理：按（`componentFile`, `line`）顺序的第一个匹配记录作为解析目标；多匹配的选择器会被标记，但 metric 中使用第一个命中。

表 1 误修复探针 (§3.1)。两个提示变体产出完全一致的数字：软提示守门规则并不降低隐性误修复。

prompt	放弃(好)	误修复(坏)	未解析	误修复 %
VANILLA	13	59	3	78.7%
+ 放弃守门规则	13	59	3	78.7%

$n = 75$ 个可达 `koenig` 失效用例。Ground truth 目标已从候选集中移除；任何被给出的可解析选择器即为一次隐性误修复。78.7% (59/75) 的 Wilson 95% 置信区间约为 [68.1%, 86.4%]。

表 2 Vanilla 与 Abstain 的逐用例配对交叉表 (§3.1, $n = 75$)。所有非对角元素均为 0，表明两变体在每一个用例上给出完全相同的判定，而非仅聚合计数相同。

Vanilla \ Abstain	放弃	误修复	未解析
放弃(好)	13	0	0
误修复(坏)	0	59	0
未解析	0	0	3

在 `temperature=0` 的确定性解码下，75 个用例的逐例标签两两一致
(off-diagonal = 0, $\Delta = 0$)。

3.1 F1: 目标缺失下的隐性误修复

设置。 对 75 个可达的 `koenig` 失效用例（即失效 commit 处 `LocatorSheet` 中存在真值 (ground truth) 元素的用例），本文以相同的提示与检索条件重跑 L3 修复器，但将真值元素从 `LocatorSheet` 与候选集中强制移除，使模型在字面意义上无法选中正确答案。此时正确响应应当是放弃 (CANDIDATE_IDX: -1)；任何给出可解析选择器的响应都是一次会沉默地将测试改写到错误元素上的隐性误修复。

我们比较两个提示变体：

1. VANILLA：与 L3 基线相同的系统提示。
2. ABSTAIN：同一提示外加一条明确的“如无候选契合则放弃”守门规则，告诉模型“一次沉默地把测试改写到错误元素上的盲修复永远比放弃更糟”。

结果。 表 1 给出结果。

为排除“聚合计数偶然相同”的可能，表 2 给出两提示变体的逐用例配对交叉表。

解读。 78.7% 是隐性误修复的上界，因为每个用例都是对抗性构造。在混合作业负载下，只有 L1 sheet 缺失目标的用例（本试点中是 $18/93 = 19\%$ 的 `koenig` 失效）面临此风险；朴素地相乘得到 $\approx 0.19 \times 0.79 = 15\%$ ，作为一个粗略的风险估计、而非测量到的部署

率（对抗性探针的行为不必一对一地迁移到真正只在运行时可达的用例上）。即便作为风险估计，我们仍认为这已经高到不能允许 CI 无人值守地自动提交 LLM 提议的选择器补丁。

VANILLA 与 ABSTAIN 之间的等同性是更具诊断意义的发现，且这一等同性是逐用例成立的（表 2：75 个用例的配对判定无一发生改变）：一个 7B 规模的代码模型在该任务上不会因软提示式的守门规则而改变其可观察行为。任何稳健的放弃机制都必须置于模型之外：例如确定性的检索分数阈值、锚点类别归属规则，或能够证伪通过补丁的行为验证器。该结果从实证层面支持将 HealReact 的 L4 层（行为重放验证器）作为下一层加以构建，而非依赖提示级别的安全网。

3.2 F2: L3 基线与两个低成本确定性手段

设置。 在同样的 75 个可达 koenig 失效用例上，我们评估两个 L3 变体：

- v0（基线，两杠杆均关）：候选按与断裂选择器的词元重叠程度检索，所有锚点（含 testId）统一权重；无后置过滤；系统提示要求模型优先选择 testId 类锚点。
- v1（两杠杆均开）：(i) 检索打分器把 testId 匹配加权 ($\times 3$) 排在 dataAttr key/value ($\times 2$) 和 aria/id/class/text/path ($\times 1$) 之上；(ii) 一个确定性强锚点后置过滤器：当所选候选携带 testId 但模型给出的不是 testId 选择器时，将其确定性地重写为 `getByTestId(testId)`。系统提示不变。

为分离两个杠杆各自的贡献，我们进一步以二因子析因（testId 加权 $\in \{\text{关}, \text{开}\} \times$ 后置过滤 $\in \{\text{关}, \text{开}\}$ ）跑满 4 个臂（表 4）。所有臂均使用 `qwen2.5-coder:7b, temperature=0`、同一系统提示；Ground truth 是 ReproBreak 中 `new_locator` 字符串所匹配的目标元素（经解析器解析）。

结果。

解读。 两项手段均成本低廉（一次正则优先级调整、一段约 10 行的后置过滤）、完全确定性、无需任何模型再训练。借助表 4 的二因子析因可分离两者贡献：以“两杠杆均关”为基线（55/75），单开 testId 加权检索与单开强锚点过滤各带来 +2 个精确匹配，两者全

表 3 L3 v0 $\rightarrow$ v1 端到端对比（75 个可达 koenig 失效）。v1 = v0 + testId 加权检索 + 强锚点后置过滤；v0 为两杠杆均关的统一权重基线。

指标	v0（两杠杆关）	v1（两杠杆开）
top-1 精确元素匹配	55 / 75 (73.3%)	58 / 75 (77.3%)
有效 Playwright 选择器	68 / 75 (90.7%)	68 / 75 (90.7%)
静态修复代理（全量 93）	55 / 93 (59.1%)	58 / 93 (62.4%)
强锚点后置过滤触发	0	2 / 75（两次都正确）
新增正确用例（vs v0）	—	3
回归用例（vs v0）	—	0

表 4 两杠杆二因子析因（top-1 精确元素匹配， $n = 75$ ）。行 = testId 加权，列 = 强锚点后置过滤。每个杠杆单独带来 +2、两者合计 +3、零回归；方向一致但在该样本量下未达统计显著。

	过滤：关	过滤：开
加权：关	55 / 75	57 / 75
加权：开	57 / 75	58 / 75

McNemar 精确检验（双侧）：单开加权或单开过滤相对“两关”均为 $+2 / -0$ ($p = 0.50$)；两者全开相对“两关”为 $+3 / -0$ ($p = 0.25$)。所有差异方向一致、零回归，但在 $n = 75$ 下均未达 $p < 0.05$ 。

开合计 +3、且零回归；强锚点后置过滤器在 v1 中独立触发 2 次且两次均正确，消除了“LLM 选中正确候选但在生成选择器时挂到了不稳定锚点上”这一失败模式。须如实说明：这些增益方向一致、无一造成回归，但在 $n = 75$ 的样本量下经 McNemar 精确检验均未达统计显著 ($p \geq 0.25$)；因此我们把它们定位为“低成本、零回归的确定性工程杠杆”，而非已被统计确立的性能提升。该结果与 F1 相互呼应：在确定性介入有效之处，提示级介入往往力有未逮。

3.3 F3: 跨应用泛化与 BEM 盲区

设置。 任何仅在单一应用上完成的试点都可能被审稿人合理质疑：所学到的可能只是应用专有的约定。为此本文以 `git sparse-checkout` 方式仅检出 `payloadcms/payload` [12] 的最新版本（HEAD；ReproBreak 中第二大的 Playwright 案例组，包含 319 个失效配对），在 `packages/ui/src` 上运行未修改的 L1 抽取器，产出 457 条记录。对每个失效配对，使用 `new_locator` 字符串在该记录表上做解析匹配（以 HEAD 版本可达率作为代理指标，逐 commit 配对未纳入本文）。

结果。 原始 3.8% 看起来灾难性，但对 307 个未命中用例的检查给出干净的故事。payload 使

表 5 跨应用 L1 可达率 (§3.3)。原始下降是真实的，但成因可诊断。

指标	koenig	payload
抽取器记录数 (均值/单次)	每 commit 约 400	457 (HEAD)
Playwright 失效配对	93 (已复现)	319 (CSV)
new_locator 可达	75 / 93 = 80.6%	12 / 319 = 3.8%
主导锚点	data-k ^g -* (约 50%)	CSS class [†]
模板字面量 class?	罕见	普遍 (BEM)

[†]payload 的主导锚点占比来自对 307 个未命中用例的采样，而非全量失效分布。

用 BEM [13]: 每个组件声明一个 `baseClass` 常量 (例如 `const baseClass = 'dashboard'`), 并以 `{`${baseClass}__add-button`}` 这样的模板字面量写出 `className`。测试引用渲染后的类 `.dashboard__add-button`, 这对一个纯字面量的 AST 抽取器是不可见的。

解读。 这一结果并非对 HealReact L1 设计的否认，而是识别出一处范围明确的盲区，其修复对应一次确定性的 AST 处理：构造一个 `baseClass` 解析器，回溯到常量声明并展开其模板字面量，并配以一个 CSS Modules [16] 等价的展开器。基于对 307 个未命中用例的非系统采样，本文假设修复后原始可达率会显著抬升，但该结论尚属假设而非测量；对全部 307 个未命中用例做系统化的失因标注 (BEM、CSS Modules、运行时 DOM、解析器局限等类别计数)、固定 payload 逐 commit 与 `ReproBreak` 配对对齐，均留作后续工作 (本文所用 payload HEAD 快照的 commit 标识随工件发布)。3.8% 是当前抽取器下诚实的原始测量值。该发现真正的贡献是这条可证伪的跨应用泛化假设本身：锚点文化的多样性 (`data-testid` vs 自定义 `data-*` vs BEM 模板字面量) 很可能是定位器修复工具泛化能力的关卡，任何仅在单一应用上完成基准测试的工具都可能高估其泛化性。

4 讨论与局限

78.7% 对无人值守 CI 自愈意味着什么。 LLM 自愈最常见的部署模式是高度自主化的：一个失败的端到端测试触发 LLM 给出补丁，CI 自动提交补丁或将其作为 PR 评论发出。由 F1 的对抗性上界粗略换算，在不带行为验证器 (oracle) 的此类部署中，约 15% (粗略上界估计，非实测部署率) 的真实 Playwright 断裂存在被朴素修复器静默改写到错误元素的风险。其危险并不在于“修复器让构建失败”——构建失败

本就是测试应承担的职责——而在于“修复器使构建通过，但通过对的是错误的目标”。

为什么软提示安全网会失效。 VANILLA 与 ABSTAIN 两种提示之间的等同性 (表 1) 并不令人意外。一种可能的解释是：系统提示中“必要时放弃”的软指令需与“产出像样答案”这一更强先验竞争，多数情况下处于劣势 (此为机理层面的推测，本文未做训练动力学层面的验证)。对工具设计的启示是清晰的：反误修复的安全保障必须置于模型之外，例如确定性的检索分数阈值、锚点类别归属规则，以及一个能够证伪通过补丁的行为验证器。

为什么两个廉价确定性杠杆胜过提示工程。 F2 的 `testId` 加权检索与强锚点后置过滤在机制上显而易见。经二因子析因分离，二者各带来 +2、合计 +3 个精确匹配且零回归 (§3.2 表 4)；增益方向一致，但在 $n = 75$ 下经 McNemar 精确检验未达统计显著。因此我们既不声称其统计显著、也不声称能泛化到当前设置以外，而是把它当作 HealReact 的一条局部设计经验：把锚点优先级约束放到候选池里和输出后置过滤里，比依靠系统提示让模型把约束内化更可靠，且不引入回归。

局限。 模型范围。本文全部数字基于单一开源小型代码模型 (`qwen2.5-coder:7b`)。前沿大模型 (如 GPT-4 类) 是否能在 F1 维度上显著缩小该差距尚待实测；根据 `VANILLA = ABSTAIN` 等同性所揭示的机理，我们倾向于认为单凭规模不足以在缺乏外部确定性验证器的前提下闭合该差距。基准数据集范围。主结果来自单一 `React+Playwright` 代码库 `koenig`；F3 中已扩展至 `payload`，但其可达率受到 BEM 类名盲区的限制。静态修复代理与运行时通过率。77.3% / 62.4% 这两个 L3 数字反映的是选择器解析器层面的精确一致性。其与真实 Playwright 运行时通过率之间的换算关系，需要在 `ReproBreak` 提供的逐 commit 复现环境中通过 Docker 重放打过补丁的测试加以建立。

有效性威胁。 78.7% 这一数字依赖解析器语义。`resolve_locators.py` 把动态 JS 表达式属性值视为可能匹配、对复合 CSS 使用祖先过近似；这两项决策在 `triage` 场景下合理，但在边界情况下偏松。我们在解析器假设审计中撤回了早期“可达率上限 98%”的虚抬声明，在收紧解析器假设后以 80.6% 作

为保守数字。由于解析器是本文所有“正确匹配/误修复/可达率”判定的事实 oracle，其判定边界会直接影响这些数字；本文尚未单独报告 strict 与 permissive 两套解析器假设下的敏感性结果、也未逐项给出多匹配与未解析用例的细分计数，这类解析器敏感性扫描（以及对抽样用例用真实 DOM 快照交叉校验）留作后续工作。

未来工作。 本文的诊断结论自然延伸出两类可推进的工程化方向：其一，将静态基底向跨锚点文化（BEM 模板字面量、CSS Modules 等）扩展，使可达率在不同 React 项目中保持稳定；其二，沿 §3 给出的经验性必要性，构建并集成一个基于网络行为重放的轻量级验证器，作为 LLM 修复结果的下游守门。

5 结论

在缺乏行为验证器 (oracle) 的部署条件下，LLM 驱动的 Playwright 自愈与“测试通过但真实回归被遮蔽”之间仅一步之遥。本文在对抗性极限下、于选择器解析层面测量到 78.7% 的隐性误修复上界，而提示级放弃指令所带来的缓解恰好为零；该数字为静态诊断指标，与运行时测试通过率之间的换算仍需基于 Docker 的真实重放。HealReact 的 L1 基底使 koenig 数据集中 80.6% 的真实失效在静态层面可达；一个小型本地修复器在可达用例上的 top-1 选择器精确匹配率达到 77.3%；两个低成本确定性手段进一步给出了帕累托改进。三项结果合起来，为后续工作中评估行为重放验证器给出了直接的经验性动机，也给出了一条由锚点文化差异所限制的、可证伪的跨应用泛化假设。

参考文献

- [1] 王赞, 樊向宇, 樊钰玮, 等. 图形用户界面测试中的脚本演化问题研究综述[J]. 软件学报, 2021, 32(7): 2173-2197.
- [2] 张涛, 姜淑娟, 鞠小林. Web 应用程序自动化测试研究综述[J]. 计算机科学, 2022, 49(6): 1-15.
- [3] Healenium Contributors. Healenium: Self-healing library for Selenium-based tests[EB/OL]. 2024[2026-06-20]. <https://healenium.io>.
- [4] JOSEPH R N. Beyond LLM-based test automation: A zero-cost self-healing approach using DOM accessibility tree extraction[EB/OL]. 2026[2026-06-20]. <https://arxiv.org/abs/2603.20358>.
- [5] DE MOURA T S, ADAMIETZ L, MEHBOOB S, et al. ReproBreak: A dataset of reproducible web locator breaks[EB/OL]. 2026[2026-06-20]. <https://arxiv.org/abs/2605.12158>.
- [6] 李戈, 彭鑫, 王千祥, 等. 大模型 + 软件工程: 研究现状与展望[J]. 软件学报, 2024, 35(1): 1-25.
- [7] 陈翔, 顾庆, 周明辉, 等. 基于人工智能的软件测试技术研究综述[J]. 计算机研究与发展, 2024, 61(2): 354-380.
- [8] HUI B, YANG J, CUI Z, et al. Qwen2.5-Coder technical report[EB/OL]. 2024[2026-06-20]. <https://arxiv.org/abs/2409.12186>.
- [9] Ghost Foundation. koenig-lexical: Ghost's Lexical-based rich-text editor[EB/OL]. 2025[2026-06-20]. <https://github.com/tryghost/koenig>.
- [10] 刘辉, 张鹏, 吴毅坚. 不稳定测试用例 (Flaky Tests) 研究综述[J]. 软件学报, 2023, 34(1): 1-26.
- [11] Meta Open Source. Lexical: An extensible text editor framework[EB/OL]. 2025[2026-06-20]. <https://lexical.dev>.
- [12] Payload CMS Inc. Payload CMS: Headless Node.js CMS on Next.js[EB/OL]. 2025[2026-06-20]. <https://payloadcms.com>.
- [13] Yandex. BEM: Block, element, modifier CSS methodology[EB/OL]. 2009[2026-06-20]. <https://en.bem.info/methodology/>.
- [14] SHERRET D. ts-morph: A TypeScript compiler API wrapper for programmatic code manipulation[EB/OL]. 2024[2026-06-20]. <https://github.com/dsherret/ts-morph>.
- [15] Ollama Contributors. Ollama: Local inference for open-weights LLMs[EB/OL]. 2024[2026-06-20]. <https://ollama.com>.

- [16] CSS Modules Authors. CSS Modules: Locally-scoped CSS class names[EB/OL]. 2020[2026-06-20]. <https://github.com/css-modules/css-modules>.