人机强合作系统中人工智能失效引发人类作业负荷变化的动态模型探讨

■ 左义涵 王晗曦 肖泽元 陈佳茜

为探究人机强合作系统中人工智能（AI）失效对人作业负荷的复杂影响，本文基于认知负荷理论及 NASA-TLX 评估方法，从人类适应性行为、任务依赖性、非线性响应 3 个角度，分析 AI 失效引发作业负荷剧增的内在机制。以自动驾驶和医疗诊断为例，揭示 AI 失效对人类操作员负荷管理的重要性，针对传统线性模型的局限性，提出融合深度学习与强化学习的动态预测模型，通过 MLP 非线性建模、RL 适应性算法、GNN 依赖性建模及多源数据融合，构建可实时预测负荷变化的精准模型。结果表明，作业负荷响应呈非线性特征，传统模型易误判压力场景下的负荷峰值，本文提出的动态模型为精准评估负荷趋势提供核心支撑，对人机系统风险管控具有指导意义。

一、AI 失效导致人类作业负荷变化模型研究

（一）人机强合作的兴起与应用

人机强合作通过深度融合人类创造力与 AI 的数据处理能力，在医疗、自动驾驶等领域得到广泛应用[1]。然而，AI 系统可能因算法缺陷、数据偏差等原因失效，不仅造成功能中断，还可能导致灾难性后果，当 AI 失效时，人类操作员需要承担额外任务，如异常检测、故障诊断与系统接管等，显著增加工作负荷[2]。因此，深入理解 AI 失效对作业负荷的影响机制，是评估系统风险、优化人机交互的关键。

（二）研究现状及研究目的

目前，关于人机交互（HCI）和人机协作（HAI）的研究日益丰富，涉及理论模型、评估方法及具体应用等多个层面。现有文献已初步表明，自动化系统或 AI 的失效会对人类操作员产生显著影响，其中作业负荷的变化是关键表征之一。

本文旨在系统探讨 AI 失效引发人类作业负荷变化的内在机制与规律，内容包括如下几点：第一，梳理人机协作中作业负荷相关的核心理论框架与关键概念；第二，分析人类适应性行为，探讨任务依赖性在人机协作系统中如何调节 AI 失效对工作负荷分配和系统鲁棒性的影响；第三，审视传统线性模型在描述任务负荷与人类工作负荷关系上的局限性；第四，结合自动驾驶、医疗诊断等领域的实际案例，剖析 AI 失效对人类操作员的具体影响；第五，探讨构建能够捕捉人类适应性、信任动态及其他复杂因素的动态作业负荷模型的必要性与可能路径。该方法通过优化生成对抗网络提升了手势识别的实时性与准确性，为 AI 失效后人类快速识别异常行为提供了技术参考。

二、实际应用场景案例剖析

以上系统分析了影响 AI 失效后人类作业负荷的关键因素，包括人类适应性、任务依赖性。为了更具体地阐释这些理论因素在现实世界中的表现及其相互作用，本文选取的自动驾驶和医疗诊断这两个领域，这两个领域人机强合作已广泛渗透且备受关注，可以剖析其中 AI 失效对人类操作员产生影响的典型案例。

（一）自动驾驶领域的 AI 失效案例

在自动驾驶系统中，AI 组件失效会显著增加驾驶员作业负荷。失效类型包括感知系统失效（如未识别障碍物）和预测决策失效（如“幽灵刹车”）。这些失效对驾驶员产生了三方面影响：任务层面需要瞬间接管控制，任务负荷剧增；认知层面需要快速完成态势感知与决策，认知负荷骤升[3]；心理层面面临碰撞风险，产生压力与信任危机。驾驶员通过紧急接管和调整监控策略等行为进行适应，但这

中国知网 https://www.cnki.net

些适应性行为本身会增加日常负荷。该案例体现了3个关键因素：人类适应性表现为快速反应但伴随认知代价；任务依赖性使单点失效直接转化为负荷冲击；状态切换呈现非线性特征，易超出认知阈值。

（二）AI 辅助医疗诊断领域的失效案例

在医疗诊断领域中，AI 失效对医生工作负荷产生复杂影响。典型失效包括错误建议、性能不稳定及输出不透明，从任务、认知和心理 3 个层面加重医生负担：任务层面需要额外验证结果，延长诊疗流程；认知层面要求更高警惕性，提升决策复杂度；心理层面产生责任压力与伦理焦虑。医生通过建立复核机制和动态校准信任等认知活动进行适应，但负荷成本高昂。该案例揭示了关键因素作用：医生的批判性思维体现认知适应性；诊断流程的顺序依赖性使验证负担转移；信任崩溃可能引发负荷剧增，认知努力呈非线性增长。这些因素都凸显了医疗场景中 AI 失效影响的复杂性。

三、面向 AI 失效的作业负荷动态模型探讨

上文分析表明，AI 失效对人类作业负荷的影响呈现高度复杂、动态和非线性的特征。这一过程不仅涉及任务需求的瞬时变化，还受到人类适应性行为、任务结构特性以及信任、疲劳等多种心理生理因素的共同影响。传统的基于静态假设或线性外推的负荷模型难以有效应对这一复杂挑战。

（一）现有模型的局限性与动态模型的必要性

当前广泛使用的作业负荷评估方法，如基于主观报告的 NASA-TLX 或 SWAT，虽然能够提供任务后操作员的整体负荷感知，但难以捕捉 AI 失效发生时及之后作业负荷的实时动态变化——包括负荷的峰值、波动以及随时间演变的适应性调整过程。传统评估方法如 NASA-TLX 难以捕捉负荷实时动态变化，且基于线性假设，在认知极限或突发事件下严重失真[4]，迫切需要构建能够整合多重影响因素、反映时变特性和非线性动态的新型作业负荷模型。

（二）动态作业负荷模型的关键要素

一是人类适应性的时间动态。需要刻画负荷随时间的演变过程，包括失效初期的负荷剧增、通过学习和策略调整带来的负荷平稳（学习曲线效应），以及长期高负荷导致的疲劳累积和绩效下降。

二是信任的动态演化。模型应反映信任水平随 AI 可靠性表现的波动，及其对操作员监控策略和依赖行为的调节作用。

三是个体差异与状态。需要综合考虑经验水平、专业技能、认知能力、风险偏好及实时状态（如疲劳、情绪）等个体参数。

四是任务与环境因素。考虑任务复杂度、时间压力、环境干扰和工作空间设计等情境因素的调节作用。

五是人机交互特性。系统的透明度、反馈质量和界面易用性直接影响操作员的理解速度和干预效率。

六是生理指标的整合。脑电、心率变异性和皮电活动等生理信号可提供客观、实时的负荷指标，为实现基于生理感知的实时评估提供可能。

（三）挑战与未来研究方向

构建动态模型面临多重挑战，如模型复杂性与参数化困难、真实失效场景数据获取难、模型验证复杂度高、实时应用的计算效率要求高、个体化与泛化的平衡等。未来研究应致力于开发多模态数据融合技术，利用仿真平台安全研究失效场景，探索可解释的机器学习方法，发展在线学习和自适应参数化技术。尽管挑战重重，但开发能够捕捉动态性、非线性和多因素交互的先进模型，对深化人机交互理解和构建人本导向的协作系统至关重要。这些模型的发展将为实现更安全、更高效且符合人类因素原则的智能协作系统提供核心方法论支持。

四、基于深度学习与强化学习的作业负荷动态预测模型

在认识到传统模型的局限后，本文提出融合深度学习（DL）与强化学习（RL）的动态预测框架，以更精准地捕捉AI失效后人类作业负荷的复杂动态。

（一）基准数学模型及其局限性

为量化 AI 失效对人类作业负荷的影响，首先构建一个基础数学模型作为基准 [Source:1,2]。该模型假设总任务负载 T 可分为人类承担的部分 T_{hunman} 和 AI 承担的部分 T_{AI}。在正常情况下，人类作业负荷定义如式（1）所示：

$$W_{normal}=T_{hunman}*D_{human} \quad (1)$$

中国知网 https://www.cnki.net

式中，D_{human} 表示人类任务的难度系数。当 AI 失效时，人类需要接管全部任务，此时需要考虑任务难度变化（人类接管 AI 任务的难度 $T_{AI\ to\ human}$）、时间压力因子（$\gamma \geq 1$）和认知负荷因子（$\delta \geq 1$），从而得到失效时的总负荷如式（2）所示：

$$W_{failure}=(T_{human}*D_{human}+T_{AI\ to\ human})*\gamma*\delta \quad (2)$$

为进一步反映人类通过适应性行为减轻额外负荷的能力，引入一个静态适应性因子 β（$0 \leq \beta \leq 1$），最终作业负荷变化量 ΔW 如式（3）所示：

$$\Delta W=[T_{human}*D_{human}*(\gamma*\delta^{-1})+T_{AI\ to\ human}*\gamma*\delta\ ]*(1-\beta) \quad (3)$$

该模型提供了一个初步的量化框架，清晰地展示了任务转移、难度变化、时间与认知压力以及人类适应性对负荷变化的影响。基础数学模型量化了任务转移、难度变化等对负荷的影响，但存在线性假设局限、静态适应性、缺乏任务依赖性和未区分失效类型等不足。

（二）利用 DL/RL 构建优化的动态模型框架

为解决上述局限，本文构建了多层次的动态模型框架。该框架集成多种先进技术方法：采用模型预测控制（MPC）技术为动态模型中的负荷补偿机制提供算法参考；基于多层感知机（MLP）学习非线性关系；使用 RL 将适应过程建模为序列决策问题；利用 GNN 显式刻画任务依赖结构；通过贝叶斯神经网络量化不确定性；融合多源异构数据以增强模型表征能力；引入在线学习机制实现模型的自适应更新。

采用 MLP 直接学习输入特征与作业负荷间的复杂非线性关系，克服传统线性公式的不足，如式（4）所示：

$$W=f_{MLP}(Features) \quad (4)$$

利用图神经网络（GNN）显式刻画任务依赖结构，将子任务作为节点、依赖关系作为边，通过图上的信息传播学习依赖结构对负荷的影响。采用贝叶斯神经网络等技术，输出负荷预测的概率分布，为风险评估提供支持，能够处理错误反馈（增加纠错负荷）、无反馈（提升决策负荷）和延迟反馈（加剧等待与重评估负荷），引入失效类型变量和特定影响因子，实现精细化的负荷预测。

（三）模型优势与应用展望

相比基准模型，DL/RL 框架具有显著优势：突破线性假设、实现动态适应性建模、显式考虑任务依赖、量化不确定性、融合多源数据并支持在线学习。以自动驾驶为例，该框架可融合多源数据预测不同失效场景下的驾驶员负荷，为自适应辅助系统提供决策支持。通过深度学习与强化学习的融合，为构建能够准确反映 AI 失效后负荷复杂动态的模型提供了强大工具，代表了未来人机强合作系统风险管理研究的重要方向。

五、结语

AI 失效通过复杂、动态且非线性的过程影响作业负荷，主要受人类适应性、任务依赖性和非线性响应 3 个关键因素调节。通过对自动驾驶与医疗诊断领域的典型案例分析，进一步验证了上述因素在实际场景中的具体表现与交互作用。因此，需要采用先进动态模型来精确预测和理解 AI 失效情境下的作业负荷变化。

引用

[1] 范海敏,高宣扬.人机交互复杂社会系统中的信任问题分析与信任机制构建[J].江苏社会科学,2025(2):63-72.

[2] 李洲,王星捷,韩楠,等.多域人机交互场景下中文SQL生成算法[J].重庆理工大学学报(自然科学),2025(11):100-107.

[3] 边坤,韩冬楠,李思雨,等.多模态人机交互设计研究进展[J].机械设计,2024(11):199-204.

[4] 康进,刘晓峰,周毅,等.考虑日内温度变化的夏季温敏负荷模型及其时变参数的两阶段辨识方法[J].电力自动化设备,2024(6):210-216.

作者简介：左义涵，西安科技大学，本科，研究方向为安全科学与工程；王晗曦，西安科技大学，本科，研究方向为车辆工程；陈佳茜，西安科技大学，本科，研究方向为材料科学与工程。

通讯作者：肖泽元，西安科技大学，硕士研究生，工程师，研究方向为人工智能系统失效风险评估、安全管理。

中国知网 https://www.cnki.net